


Generative Adversarial Nets


Lucas Borsatto Simão, Iniciação Científica em Machine Learning

Meetup Machine Learning Rio de Janeiro



Background

GANs



Tipos de aprendizado

Supervisionado

- Um conjunto x de dados possuem rótulos y ;
- Objetivo do algoritmo é prever a saída y dada uma entrada x ;

Não supervisionado

- O conjunto x de dados não é rotulado;
- O algoritmo tenta entender a estrutura presente nos dados x ;

Modelos de aprendizado

Discriminativo


- Representa a função que mapeia os dados x aos rótulos y ;
- Aprende a probabilidade condicional $P(y|x)$;

Generativo

- Representa a função que mapeia x e y dado somente o x ;
- Aprende a probabilidade conjunta $P(x, y)$;


Discriminativos vs Generativos

Redes Neurais




$$\begin{aligned} &P(y = 0 \mid x) \\ &P(y = 1 \mid x) \\ &P(y = 2 \mid x) \\ &\vdots \\ &P(y = 9 \mid x) \end{aligned}$$

Generative Adversarial Nets (GANs)




$$P(x, y)$$



Uso de modelos generativos

Para que servem



Utilização de modelos Generativos



Denoising

Utilização de modelos Generativos




Inpainting

Utilização de modelos Generativos




Transferência de estilos

Fonte: <https://arxiv.org/abs/1603.03417.pdf>



GANs

Generative Adversarial Networks



Conceitos básicos


- Modelo revolucionou a área de *Generative Models*;
- Criado por Ian Goodfellow, em 2014;

"GANs and it's variations are the most interesting idea in 10 years in ML", Yan Lecunn, diretor do departamento de pesquisa do Facebook.

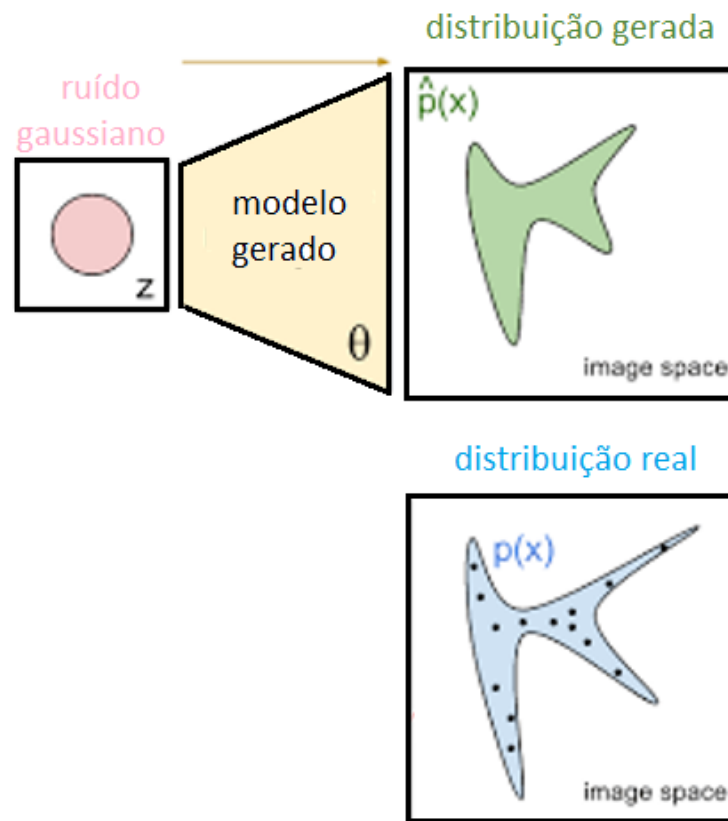
Conceitos básicos

- Usa um vetor latente z ;
- São dois modelos que competem entre si;
- Modelo gerador tenta criar imagens próximas das reais para confundir o discriminador;
- O discriminador tenta adivinhar qual imagem é falsa e qual é real;


Estrutura de uma GAN




Estrutura de uma GAN



Estrutura de uma GAN




Aprendizagem




- Processo inicialmente possui tanto $G(z)$ quanto $D(x, G(z))$ imprecisos;

Aprendizagem




- A medida que o $D(x, G(z))$ melhora a precisão, $G(z)$ gera dados de maior qualidade;

Aprendizagem




- Com o tempo $G(z)$ aproxima sua distribuição de X ;

Aprendizagem




- Processo acontece até que $G(z) \sim X$ e $D(x, G(z)) \sim 0.5$;

Aprendizagem – Nash Equilibrium




- O aprendizado se trata de um jogo chamado *minimax*:
 - O Discriminador tenta aumentar as chances de classificação correta;
 - O Gerador tenta diminuir as chances de o Discriminador acertar a classificação;




Problemas ...

Adversidades encontradas no treinamento




Instabilidade no treinamento

- Dificuldade de se achar hiperparâmetros que se encaixem no problema;



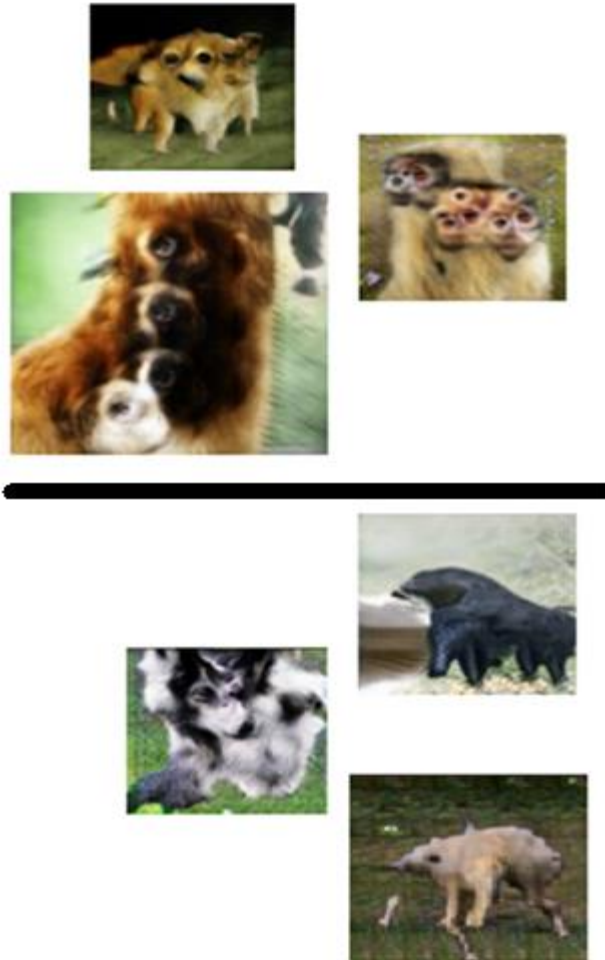
Colapso de modelo



- Um grande número de valores de z são mapeados para uma mesma resposta, sem variação;

Fonte: <https://arxiv.org/pdf/1701.07875.pdf>

Erros de conceito



- Por vezes, quando convergem, tem dificuldade em interpretar figuras 3D e discernir as propriedades da imagem;

50419213504192135041921350419213
44604567.44604567.44604567.44604567.
20271864202718642027186420271864
13591762135917621359176213591762
16375809163758091637580916375809
87609757876097578760975787609757
23949216239492162394921623949216
56799370567993705679937056799370

Avanços

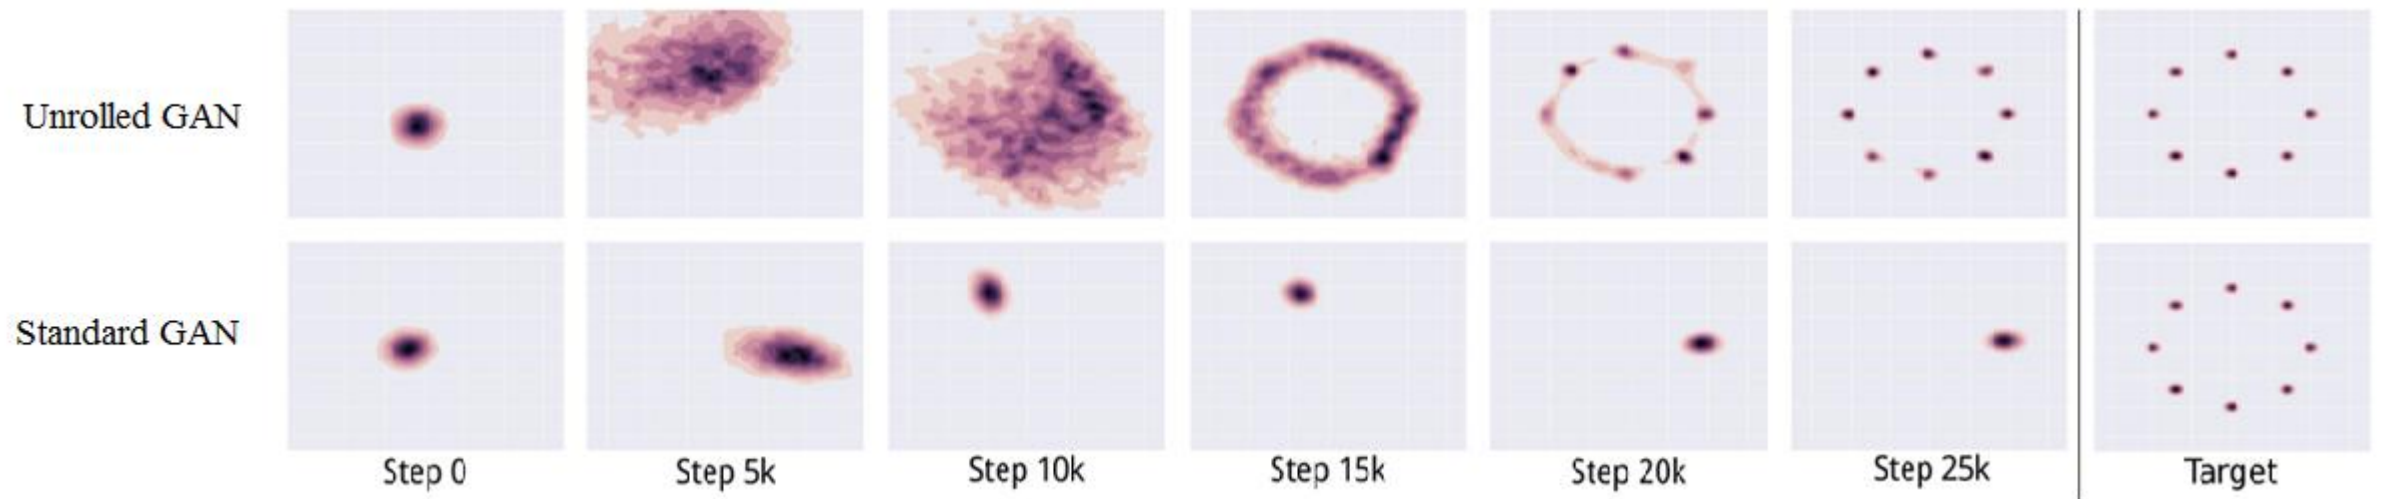
Melhorias propostas ao algoritmo

87609757876097578760975787609757
23949216239492162394921623949216
56799370567993705679937056799370

Unrolled GAN

- Objetivo é tratar do colapso de modelo;
- Função de custo é modificada para que o Discriminador antecipe os passos que serão dados pelo Gerador;
- O custo é mais alto para o gerador para passos que tendem ao colapso;

Unrolled GAN



Fonte: <https://arxiv.org/abs/1611.02163.pdf>


DCGAN

- Objetivo é mapear padrões e métodos para que o algoritmo apresente convergência;
- Implementação de CNNs junto com GANs;
- Utilização da capacidade do modelo para tarefas discriminativas;
- Operações conceituais entre imagens;

DCGAN – Conceitos utilizados

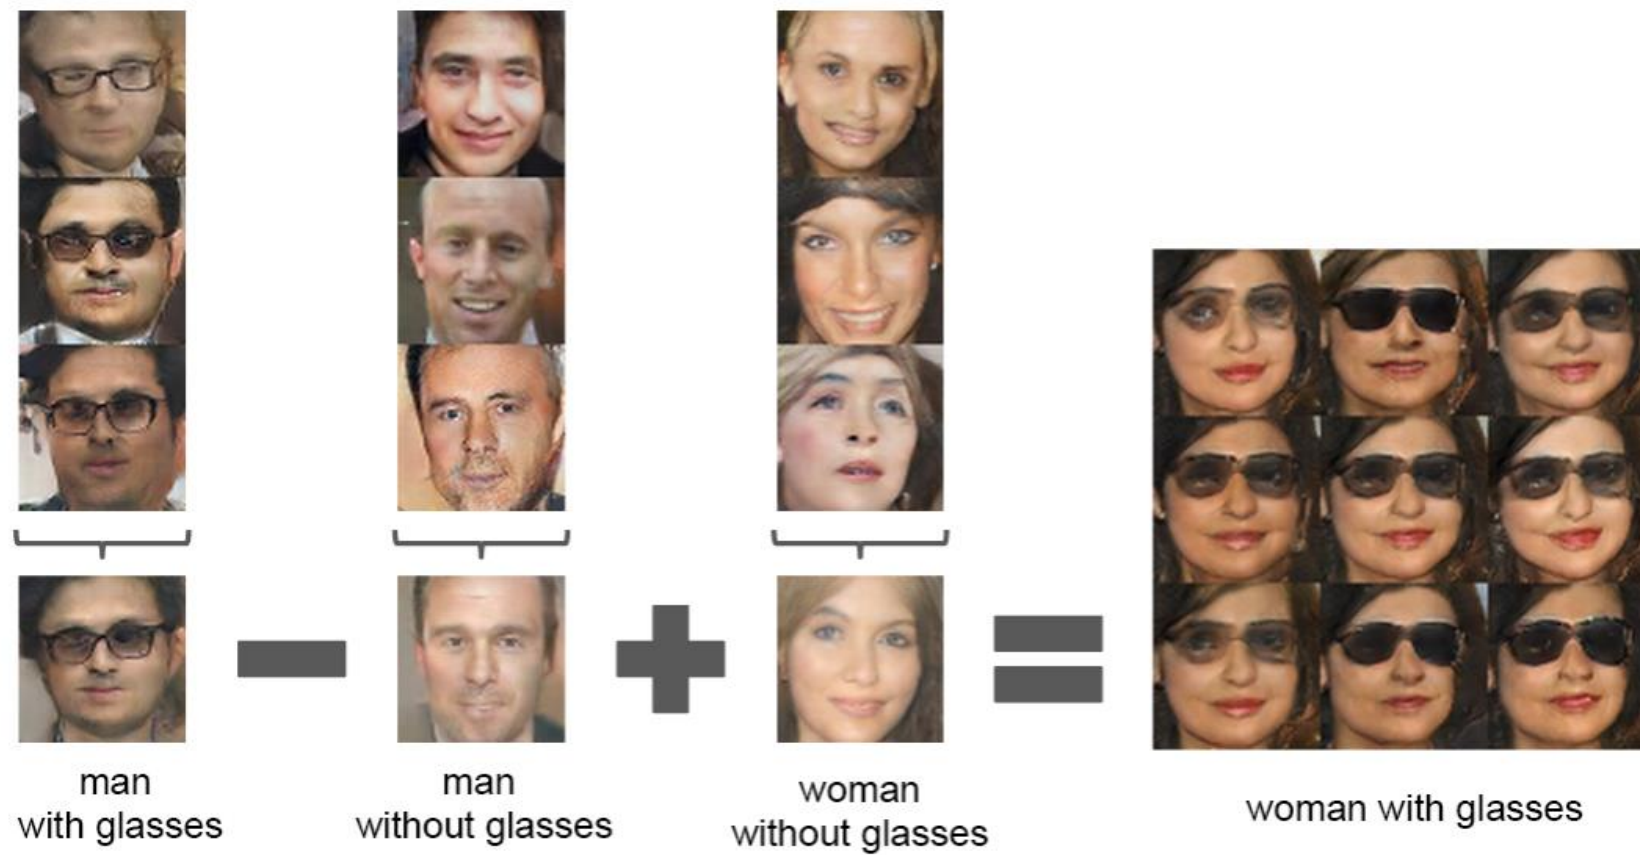
- Utilização de redes inteiramente convolucionais;
- Batch Normalization;
- Definição dos hiperparâmetros para apresentar resultados;

DCGAN - Estrutura



Fonte: <https://arxiv.org/pdf/1511.06434.pdf>

DCGAN



Fonte: <https://arxiv.org/pdf/1511.06434.pdf>

DCGAN



Fonte: <https://arxiv.org/abs/1611.02163.pdf>

Improved Techniques for Training GANs



- Melhoras sugeridas pelo mesmo autor das GANs:
 - Discriminador possui conhecimento prévio dos minibatches com o objetivo de evitar o colapso de modelo;
 - Limita o discriminador a ter respostas entre 0.1 e 0.9 ao invés de 0 e 1;
 - Virtual Batch – Gradiente baseado em batchs de referência;
- Tenta-se resolver o problema com métodos empíricos;

Principled Methods for Training GANS


- Problemas das GANs explicados matematicamente;
- Proposta de se usar função de custo baseada em distância entre os dados e não em sua semelhança;
- Torna-se base para criação das Wasserstein GANs;

Principled Methods for Training GANS

- Distância da dados dispostos entre duas retas;

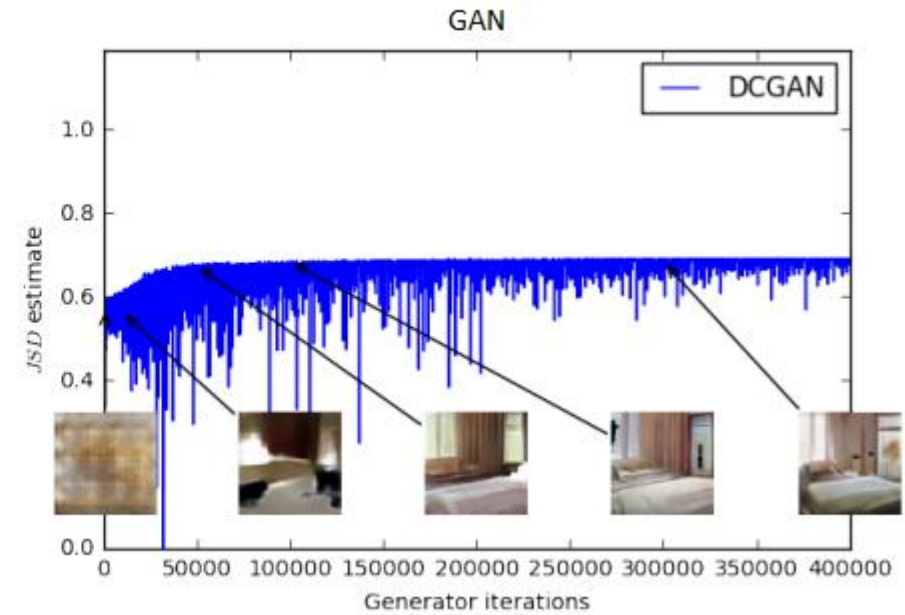
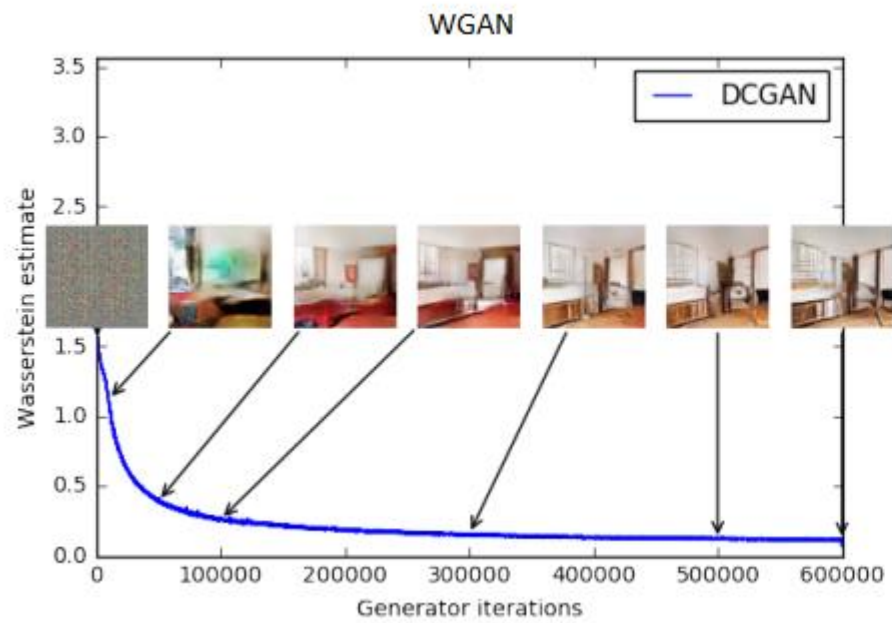


Wasserstein GAN




GANs

WGAN




Fonte: <https://arxiv.org/pdf/1701.07875.pdf>

WGAN




Fonte: <https://arxiv.org/pdf/1701.07875.pdf>



Aplicações das GANs


Algoritmos para diversas funcionalidades



InfoGAN



Neural Photo Editing



Fonte: <https://arxiv.org/pdf/1609.07093.pdf>

SRGAN – Super Resolução



Interpolação Bicubica



SRGAN



Original

Fonte: <https://arxiv.org/pdf/1609.04802.pdf>


SGAN



Input



SGAN5




Gatys et al.

Conditional GANs



Fonte: <https://arxiv.org/pdf/1701.00160.pdf>

Imitation Learning



Fonte: <https://blog.openai.com/generative-models/>

Conclusão

- GANs são modelos generativos que aprendem a partir de um espaço latente;
- É necessário encontrar o equilíbrio entre o modelo gerador e o discriminativo;
- As muitas variações possuem aplicações em diversas áreas;

Obrigado!



Lucas Borsatto

Pesquisador em Machine Learning

Engenheiro Mecatrônico

Twitter

@lucasbsimao